

AI/ML 엔지니어 · AI 분야 10년 (석사 연구 2년 + 실무 7년+)

김원혁

Portfolio

복잡한 데이터 특성을 파악해 모델 성능을 극대화하는, AI 분야 10년 차 AI/ML 엔지니어입니다 (석사 연구 포함). 보안 데이터와 같이 특수성이 강한 도메인에서도 최적의 모델을 설계하고 파인튜닝할 수 있는 응용력을 갖췄으며, TB급 대용량 데이터 처리부터 MLOps 파이프라인 구축까지 문제를 AI 기술로 해결하는 End-to-End 엔지니어링에 주력합니다. 최근에는 LLM 에이전트를 실제 서비스에 적용하는 영역으로 넓혔고, 특히 Claude Code를 적극 활용해 개발 하네스와 멀티에이전트로 개발 과정 자체를 자동화하며 여러 개인 프로젝트를 빠르게 구현하고 있습니다.

↗ [github.com/
novatecoder](https://github.com/novatecoder)

✉ novatecoder@gmail.com

↗ [Notion
Portfolio](#)

≡ 이력서 보
기

AI 개발 하 네스

링크 : [claude-code-harness-showcase](#)

여러 프로젝트와 머신을 오가며 Claude Code로 개발하는 환경을 지침·룰·서브에이전트 계층으로 직접 설계하고, 예제 하나를 기획부터 명세·위임·검증까지 관통시킨 과정을 공개한 워크드 예제입니다

티켓 라우터

링크 : [ticket-router](#)

서비스데스크로 들어오는 문의를 AI가 담당 팀에 자동 분류·배정하고, 근거가 충분한 단순 문의는 매뉴얼을 인용해 직접 답하되 민감하거나 근거가 부족하면 사람에게 넘기는 시스템입니다

문제

Claude Code를 여러 프로젝트와 머신에서 쓰다 보면 세션마다 맥락이 유실되고 품질 편차와 셀프리뷰의 한계가 반복됩니다

접근

지침(CLAUDE.md)과 룰·스킬·서브에이전트를 계층으로 쌓아 SDD 파이프라인, 리드 아키텍트 위임 사이클, 환경 적응형 테스트 티어를 하나의 개발 환경으로 엮었습니다

결과

git clone 한 번이면 어느 머신에서든 동일하게 동작하며, 예제 프로젝트 하나를 기획부터 EARS 명세·에이전트 위임·검증(테스트 통과)까지 관통시킨 과정을 공개 쇼케이스로 정리했습니다

Claude Code

SDD

서브에이전트

상세 설명

배경

여러 개인 프로젝트를 동시에 굴리며 Claude Code로 개발하다 보니, 세션이 매번 새로 시작되고 프로젝트마다 규칙이 달라 같은 시행착오를 반복하는 것이 아까웠습니다

가치

새 프로젝트를 시작할 때 검증된 개발 규칙과 위임·검증 절차가 처음부터 갖춰져 있어, 환경을 매번 다시 세팅하지 않고도 일정한 품질로 빠르게 진행할 수 있습니다

공개

github.com/novatecoder/claude-code-harness-showcase에서 기획→명세→위임→검증 워크드 예제를 직접 볼 수 있습니다

문제

서비스데스크로 들어오는 문의를 담당자가 일일이 읽고 분류·배정하다 보니 처리가 지연되고, 매뉴얼만 봐도 답할 수 있는 단순 문의에까지 사람 손이 들어갔습니다

접근

LangGraph 그래프로 문의를 담당 팀별로 자동 분류·배정하고, 근거가 충분한 단순 문의는 매뉴얼에서 근거를 찾아 인용까지 붙여 자동 답변합니다
(FastAPI·PostgreSQL·로컬 vLLM Qwen2.5-7B)

결과

서비스데스크 대체 과제의 개인 PoC로, 서로 다른 문의 5건을 자동응답 2건·사람이관 3건으로 처리하는 E2E 흐름을 검증했습니다 (mock 모드라 누가 돌려도 같은 결과가 나오고 실로직은 제품과 동일)

LangGraph

RAG

FastAPI

PostgreSQL

vLLM

데모 및 상세 설명

배경

서비스데스크 문의 자동화를 실무에서 다루게 되면서, 사내 적용에 앞서 분류·근거응답·안전 판단 같은 핵심 설계를 자유롭게 실험하고 검증할 개인 PoC가 필요했습니다

가치



반복되는 단순 문의를 근거까지 붙여 자동 응대하면서도 위험한 문의는 반드시 사람에게 넘겨, 담당자가 정밀 판단이 필요한 일에만 집중할 수 있습니다

안전 레이어(answerability)

"이 문의에 자동으로 답해도 되는가"를 별도로 판단해, 민감정보나 금지 카테고리·근거 부족 문의는 자동 응답을 막고 사람 상담원에게 이관함으로써 환각과 오응답을 막습니다

데모

문의 5건이 분류에서 근거 검색, 인용, 자동응답 또는 사람이관으로 흐르는 전 과정을 담았고, 특히 매뉴얼(M_IT01)을 근거로 든 자동답변 화면과 피상·계정도용 문의를 강제 차단해 이관하는 안전 장면, 실제 웹 접수 게시판 UI를 함께 보여줍니다



영링크 : cine-analyst-llm

영화 분석 파인튜닝

영화 줄거리·메타데이터를 이해해 분석하도록 LLM을 파인튜닝해 본 초기 실험 프로젝트 **LLM 파인튜닝**

Python

가링크 : household_ledger_ai

계부서 드바이저

여러 에이전트가 스스로 쿼리를 고쳐가며 자연어 질문에 답하고, **LangGraph** **pgvector** **Neo4j** **Redis** **가계부서 드바이저**입니다

KIS MCP 링크 : kis_mcp_server_adk
서버

증권사(KIS) API를 MCP 표준 도구로 감싸 "잔고 보여줘" 같은 자연어 명령만으로 주식 잔고 조회와 매매를 할 수 있게 한 증권 서버입니다

FastMCP

KIS-API

Ollama 링크 : DocuChatAi
RAG 문서QA

업로드한 문서를 근거로만 답하도록 RAG를 붙이고 경량 **Ollama** 모델 **OpenAI**로 돌려, 더 **LangChain** 환각 없이 내 문 **VectorDB** 수 있는 앱입니다

Streamlit

투자 에이전트 링크 : PyInvestAdvisor

뉴스·주가·재무제표처럼 흩어진 정보를 한데 모아 LLM이 매수·매도 의견을 논리적으로 정리해 주는 투자 분석 보조 에이전트입니다

Google ADK

LLM

PySpark 링크 : pyspark-nlp-pipeline
NLP 파이프라인

특정 파티션에 쏠리는 데이터(Data Skew)를 Key Salt로 흩어 TB급 텍스트를 병렬로 정제·토큰화하는 대용량 처리 파이프라인입니다

PySpark

UDF

특허 출원 자동화

특허 명세서 초안 작성과 출원 절차 LLM Python 도구로, 현재 플랫폼 준비하며 다듬고 있습니다

AI 투자 자문 시스템

MCP로 여러 시장 데이터를 한데 모아 투자 판단을 돕는 자문 시스템 MCP LLM 개발 중입니다

핵심 역량

- Agentic 개발 워크플로우: Claude Code·SDD·멀티에이전트(provider/reviewer) 오케스트레이션 기반 개발 자동화
 - LLM 파인튜닝: LoRA·DeepSpeed/Unsloth 기반 분산 학습 최적화 및 도메인 특화
 - Deep Learning Modeling: TensorFlow/PyTorch 기반 보안 도메인 맞춤형 모델 설계·최적화
 - DevOps & Environment: Docker 기반 연구 개발 환경 컨테이너화·표준화
- LLM 앱 엔지니어링: LangGraph 멀티에이전트·RAG·MCP 설계 (실무 + 개인 프로젝트)
 - MLOps Automation: Airflow/Kubernetes 기반 학습·배포 파이프라인 자동화 (CI/CD)
 - Big Data Engineering: Spark 기반 TB급 대용량 처리 아키텍처 및 비용 효율화

기술 스택

성과 보유 핵심

ADVANCED

LLM 앱 엔지니어링

- LangGraph
- RAG
- MCP

Agentic 개발

- Claude Code
- 멀티에이전트
- SDD

LLM 파인튜닝·분산학습

- LoRA
- DeepSpeed
- Unsloth
- Sequence Parallelism

ML0ps·인프라

- Airflow
- Kubernetes
- CI/CD
- Docker

딥러닝 모델링

- PyTorch
- TensorFlow
- BERT
- CNN

빅데이터·분석

- Spark
- PySpark
- Scala
- Python
- Pandas

즉시 투입

APPLY

온디바이스 LLM

LiteRT-LM

Gemma

EXAONE

llama.cpp

vLLM

벡터·검색

Qdrant

pgvector

BGE-M3

백엔드·API

FastAPI

FastMCP

MySQL

모바일

Kotlin

Android

Jetpack Compose

Room

클라우드

GCP

AWS S3

경력

2026.03-현재

메타넷디지털 (삼성 파견) · AI 엔지니어

- ◆ 서비스데스크 문의 분류·라우팅 + RAG 자동응답 시스템 설계·구현 (메인 담당)

2025.09-2026.03

개인 연구

- ◆ 최신 LLM · LangGraph · RAG · MCP 직접 구현·검증
- ◆ AI 개발 하네스 자체 설계 (현재 지속)

● 2018.07-2025.08

안랩 (AhnLab) · 선임 연구원

- ◆ Security LLM 파인튜닝 및 대규모 분산 학습 시스템 구축
- ◆ Airflow/Kubernetes 기반 MLOps 파이프라인 자동화
- ◆ TensorFlow/PyTorch 보안 도메인 특화 모델 개발
- ◆ Spark 기반 대용량 데이터 처리·비용 효율화
- ◆ 전처리/스키마 최적화로 데이터 신뢰성 확보
- ◆ Docker 기반 개발 환경 컨테이너화·표준화

상세 경력·성과(PAR)는 이력서 보기에서 확인하세요.

학력

광운대학교 대학원 · 석사 로봇학과 (지능 시스템) · 스케치 실사화를 위한 Discriminator GAN

2017.03-2019.02

광운대학교 · 학사 로봇학과 2010.03-2017.02