

김원혁

복잡한 데이터 특성을 파악해 모델 성능을 극대화하는, AI 분야 10년 차 AI/ML 엔지니어입니다 (석사 연구 포함). 보안 데이터와 같이 특수성이 강한 도메인에서도 최적의 모델을 설계하고 파인튜닝 할 수 있는 응용력을 갖췄으며, TB급 대용량 데이터 처리부터 MLOps 파이프라인 구축까지 문제를 AI 기술로 해결하는 End-to-End 엔지니어링에 주력합니다. 최근에는 LLM 에이전트를 실제 서비스에 적용하는 영역으로 넓혔고, 특히 Claude Code를 적극 활용해 개발 하네스와 멀티에이전트로 개발 과정 자체를 자동화하며 여러 개인 프로젝트를 빠르게 구현하고 있습니다.

✉ novatecoder@gmail.com

↗ github.com/novatecoder

↗ [웹 포트폴리오](#)

↗ [노션 포트폴리오](#)

학력

광운대학교 대학원 · 석사 로봇학과 (지능 시스템)
스케치 실사화를 위한 Discriminator GAN

2017.03-2019.02

광운대학교 · 학사 로봇학과

2010.03-2017.02

핵심 역량

- ◆ Agentic 개발 워크플로우: Claude Code · SDD · 멀티에이전트(provider/reviewer) 오케스트레이션 기반 개발 자동화
- ◆ LLM 파인튜닝: LoRA · DeepSpeed/Unsloth 기반 분산 학습 최적화 및 도메인 특화
- ◆ Deep Learning Modeling: TensorFlow/PyTorch 기반 보안 도메인 맞춤형 모델 설계·최적화
- ◆ DevOps & Environment: Docker 기반 연구개발 환경 컨테이너화·표준화
- ◆ LLM 앱 엔지니어링: LangGraph 멀티에이전트 · RAG · MCP 설계 (실무 + 개인 프로젝트)
- ◆ MLOps Automation: Airflow/Kubernetes 기반 학습·배포 파이프라인 자동화 (CI/CD)
- ◆ Big Data Engineering: Spark 기반 TB급 대용량 처리 아키텍처 및 비용 효율화

기술 스택

LLM 앱·에이전트

LangGraph

RAG

MCP

Claude Code

멀티에이전트

SDD

vLLM

LLM 파인튜닝·분산학습

LoRA

DeepSpeed

Unsloth

Sequence Parallelism

Deep Learning & Modeling

PyTorch

TensorFlow

BERT

CNN

Big Data & 분석

Scala

Spark

PySpark

Hadoop

Parquet

Python

Pandas

MLOps & Infra

Kubernetes

Docker

Nvidia-docker

Airflow

CI/CD

온디바이스·모바일

LiteRT-LM

Gemma

EXAONE

Kotlin

Android

Jetpack Compose

데이터·클라우드

Qdrant

pgvector

BGE-M3

FastAPI

MySQL

AWS(S3)

GCP

2018.07-2025.08 (7년 2개월)

주식회사 안랩 (AhnLab)

AI 연구원 선임

Security LLM Fine-tuning 및 대규모 분산 학습 시스템 구축

2024.01-2025.08

PROJECT GOAL 악성 행위 탐지 및 보안 인텔리전스 분석을 위한 LLM 도입 및 효율적 파인튜닝 파이프라인 구축

도메인 특화 성능 확보 (Domain Adaptation)

PROBLEM 범용 LLM의 보안 도메인 지식 부족으로 정밀한 악성 행위 탐지 불가

ACTION LoRA(Low-Rank Adaptation) 기법 도입, 보안 데이터셋으로 효율적 파인튜닝

RESULT 복잡한 악성 행위 패턴 탐지 성공, 적은 자원으로 보안 특화 모델 확보

GPU 메모리 병목 해결 및 아키텍처 최적화

PROBLEM 제한된 자원에서 대규모 모델 로딩 시 OOM 발생

ACTION DeepSpeed ZeRO Offloading·Unsloth로 메모리 최소화, Sequence Parallelism 도입

RESULT 동일 자원 내 기존 대비 2배 규모 모델 학습 환경 구현

데이터 로딩 속도 및 배포 효율 개선

PROBLEM 대규모 텍스트 데이터 I/O 병목 및 수동 배포 비효율

ACTION PyTorch DataLoader 개선(Prefetching), Kubernetes 기반 CI/CD 파이프라인 구축

RESULT 학습 속도 50% 향상, 데이터 로딩 속도 2배 이상 향상

MLOps 기반 학습 파이프라인 자동화 및 성능 최적

2023.01-2023.12

악성 행위 탐지 및 보안 LLM 성능 최적화 (2025.09-2026.03)

2025.09-2026.03

도메인 특화 성능 확보 (Domain Adaptation) 및 대규모 분산 학습까지 전 과정 자동화 및 데이터 신뢰성 확보

2025.09-2026.03

도메인 특화 성능 확보 (Domain Adaptation) 및 대규모 분산 학습까지 전 과정 자동화 및 데이터 신뢰성 확보

2025.09-2026.03

도메인 특화 성능 확보 (Domain Adaptation) 및 대규모 분산 학습까지 전 과정 자동화 및 데이터 신뢰성 확보

2025.09-2026.03

도메인 특화 성능 확보 (Domain Adaptation) 및 대규모 분산 학습까지 전 과정 자동화 및 데이터 신뢰성 확보

2025.09-2026.03

도메인 특화 성능 확보 (Domain Adaptation) 및 대규모 분산 학습까지 전 과정 자동화 및 데이터 신뢰성 확보

2025.09-2026.03

AI 엔지니어

서비스데스크 AI 자동화 (메인 담당)

AI 개발 하네스

Claude Code로 여러 프로젝트를 운영하며 겪는 맥락 유실·품질 편차를 없애려 SDD 파이프라인·리드이기력·귀금 사이클·환경적응 네트워크 언어를 갖춘 개발 하네스를 직접 설계했습니다. 예제 하나를 기획부터 EARS 명세·에이전트 위임·검증까지 관통시킨 워크드 예제를 공개 쇼케이스 repo로 정리했습니다

sift

완전 오프라인 온디바이스 LLM(LiteRT-LM+Gemma-4-E4B, GPU)이 기기 안에서 문자를 직접 읽어 중요한 것만 디지세스로 인출하고 스마트폰 온디바이스 GPU 자 원문이 기기 밖으로 나가지 않습니다 (비공개·수익화 준비)

티켓 라우터

서비스데스크 문의를 담당 팀에 자동 분류·배정하고 근거가 충분한 단순 문의는 매뉴얼을 인용해 자동 응답하며, 민감하거나 근거가 부족한 문의는 안전러 PostgreSQL abil vLLM 사람에게 이관합니다. 서비스데스크 대체 과제의 개인 PoC로 E2E까지 검증했습니다

코딩테스트 퀴즈 앱

알고리즘 43유형·426문항을 7종 퀴즈와 간격 반복(SRS)으로 자투리 시간에 복습하는 오프라인 Kotlin Jetpack Compose Room Android 앱으로, 단위 테스트 190건을 갖춰 테스트 SRS 시를 준비 중입니다 (비공개)

persona-agent

감정 엔진을 가진 캐릭터가 대화·기억·일정을 직접 관리하고 코딩 같은 태스크는 하위 에이전트에 위임하느, 단답형 완전 오프라인 개인 AI 동반자입니다

SQLite

이전 프로젝트

- ◆ **영화 분석 파인튜닝** — 영화 줄거리·메타데이터를 분석하도록 LLM을 파인튜닝한 초기 실험 프로젝트
- ◆ **가계부 AI 어드바이저** — 여러 에이전트가 스스로 쿼리를 교정하며 자연어 질문에 답하고, 가맹점 관계를 그래프로 분석해 이상 지출을 짚어주는 가계부 어드바이저 (SQL Injection 검증 노드 포함)
- ◆ **KIS MCP 서버** — 증권사(KIS) API를 MCP 표준 도구로 감싸 자연어 명령만으로 주식 잔고 조회·매매를 수행하는 중계 서버
- ◆ **Ollama RAG 문서QA** — 업로드 문서를 근거로만 답하는 RAG에 온프레미스 양자화 경량 모델을 붙여, 데이터 유출·환각 없이 문서에 질의하는 앱
- ◆ **투자 에이전트** — 뉴스·주가·재무 등 흩어진 정보를 통합해 LLM이 매수·매도 의견을 정리해 주는 투자 분석 보조 에이전트
- ◆ **PySpark NLP 파이프라인** — Data Skew를 Key Salt로 해소해 TB급 텍스트를 병렬 정제·토큰화하는 대용량 처리 파이프라인

진행 중

- ◆ **특허 출원 자동화** — 특허 명세서 초안과 출원 절차를 LLM으로 보조·자동화하는 도구 (출원 준비 중)
- ◆ **AI 투자 자문 시스템** — MCP로 시장 데이터를 통합해 투자 판단을 돕는 자문 시스템 (개발 중)

